Опорный пример для выполнения лабораторной работы по визуализации данных

1) Текстовое описание набора данных

В качестве набора данных мы будем использовать набор данных по обнаружению присутствия людей в помещении - https://archive.ics.uci.edu/ml/datasets/Occupancy+Detection+ (https://archive.ics.uci.edu/ml/datasets/Occupancy+Detection+)

Эта задача является очень актуальной для создания "умных зданий", которые выполняют все требования по кондиционированию воздуха, температурным условиям, но при этом экономят электроэнергию в том случае, если людей в помещении нет.

Датасет состоит из трех файлов:

- datatraining.txt - обучающая выборка (в этом примере используется только данный файл)
- datatest.txt - тестовая выборка
- datatest2.txt - тестовая выборка большего размера

Каждый файл содержит следующие колонки:

- date - дата-время в формате ГОД-МЕСЯЦ-ДЕНЬ ЧАСЫ:МИНУТЫ:СЕКУНДЫ. Набор данных содержит данные с интервалом измерения в минуту.
- Temperature - температура в градусах Цельсия.
- Humidity - относительная влажность в %.
- Light - освещенность в Люксах.
- CO2 - концентрация углекислого газа в миллионных долях.
- HumidityRatio - величина, производная от температуры и относительной влажности.
- Occupancy - целевой признак. Если в помещении находятся люди то 1, иначе 0.

Импорт библиотек

Импортируем библиотеки с помощью команды import. Как правило, все команды import размещают в первой ячейке ноутбука, но мы в этом примере будем подключать все библиотеки последовательно, по мере их использования.

In [63]:
```
import numpy as np
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt
%matplotlib inline
sns.set(style="ticks")
```

Загрузка данных

Загрузим файлы датасета в помощью библиотеки Pandas.

Не смотря на то, что файлы имеют расширение txt они представляют собой данные в формате CSV (https://ru.wikipedia.org/wiki/CSV (https://ru.wikipedia.org/wiki/CSV)). Часто в файлах такого формата в качестве разделителей используются символы ",", ";" или табуляция. Поэтому вызывая метод read_csv всегда стоит явно указывать разделитель данных с помощью параметра sep. Чтобы узнать какой разделитель используется в файле его рекомендуется предварительно посмотреть в любом текстовом редакторе.

In [64]:
```
# Будем анализировать данные только на обучающей выборке
data = pd.read_csv('2014_ebola.csv', sep=",")
```

2) Основные характеристики датасета

In [65]:
```
# Первые 5 строк датасета
data.head()
```

Out[65]:

	Country	Month	Year	Lat	Lon	Value
0	Guinea	3	14	9.95	-9.7	122
1	Guinea	4	14	9.95	-9.7	224
2	Guinea	5	14	9.95	-9.7	291
3	Guinea	6	14	9.95	-9.7	413
4	Guinea	7	14	9.95	-9.7	460

In [66]:
```
# Размер датасета - 8143 строк, 7 колонок
data.shape
```

Out[66]: (31, 6)

In [67]:
```
total_count = data.shape[0]
print('Всего строк: {}'.format(total_count))
```

```
Всего строк: 31
```

In [68]:
```
# Список колонок
data.columns
```

Out[68]:
```
Index(['Country', 'Month', 'Year', 'Lat', 'Lon', 'Value'], dtype='
object')
```

In [69]:
```
# Список колонок с типами данных
data.dtypes
```

Out[69]:
```
Country     object
Month        int64
Year         int64
Lat        float64
Lon        float64
Value        int64
dtype: object
```

In [70]:
```
# Проверим наличие пустых значений
# Цикл по колонкам датасета
for col in data.columns:
    # Количество пустых значений - все значения заполнены
    temp_null_count = data[data[col].isnull()].shape[0]
    print('{} - {}'.format(col, temp_null_count))
```

```
Country - 0
Month - 0
Year - 0
Lat - 0
Lon - 0
Value - 0
```

In [71]:
```
# Основные статистические характеристки набора данных
data.describe()
```

Out[71]:

	Month	Year	Lat	Lon	Value
count	31.00000	31.0	31.000000	31.000000	31.000000
mean	8.16129	14.0	9.328710	-10.097097	991.741935
std	2.59611	0.0	3.026781	2.163978	1103.731005
min	3.00000	14.0	6.430000	-14.450000	1.000000
25%	6.00000	14.0	6.430000	-11.780000	114.500000
50%	8.00000	14.0	8.460000	-9.700000	533.000000
75%	10.00000	14.0	9.950000	-9.430000	1625.500000
max	12.00000	14.0	17.570000	-4.000000	3567.000000

In [72]:
```
# Определим уникальные значения для целевого признака
data['Month'].unique()
```

Out[72]:
```
array([ 3,  4,  5,  6,  7,  8,  9, 10, 11, 12])
```

Целевой признак является бинарным и содержит только значения 0 и 1.

3) Визуальное исследование датасета

Для визуального исследования могут быть использованы различные виды диаграмм, мы построим только некоторые варианты диаграмм, которые используются достаточно часто.

Диаграмма рассеяния (https://en.wikipedia.org/wiki/Scatter_plot)

Позволяет построить распределение двух колонок данных и визуально обнаружить наличие зависимости. Не предполагается, что значения упорядочены (например, по времени).

In [73]:
```
fig, ax = plt.subplots(figsize=(10,10))
sns.scatterplot(ax=ax, x='Month', y='Value', data=data)
```

Out[73]: <matplotlib.axes._subplots.AxesSubplot at 0x130b96a90>

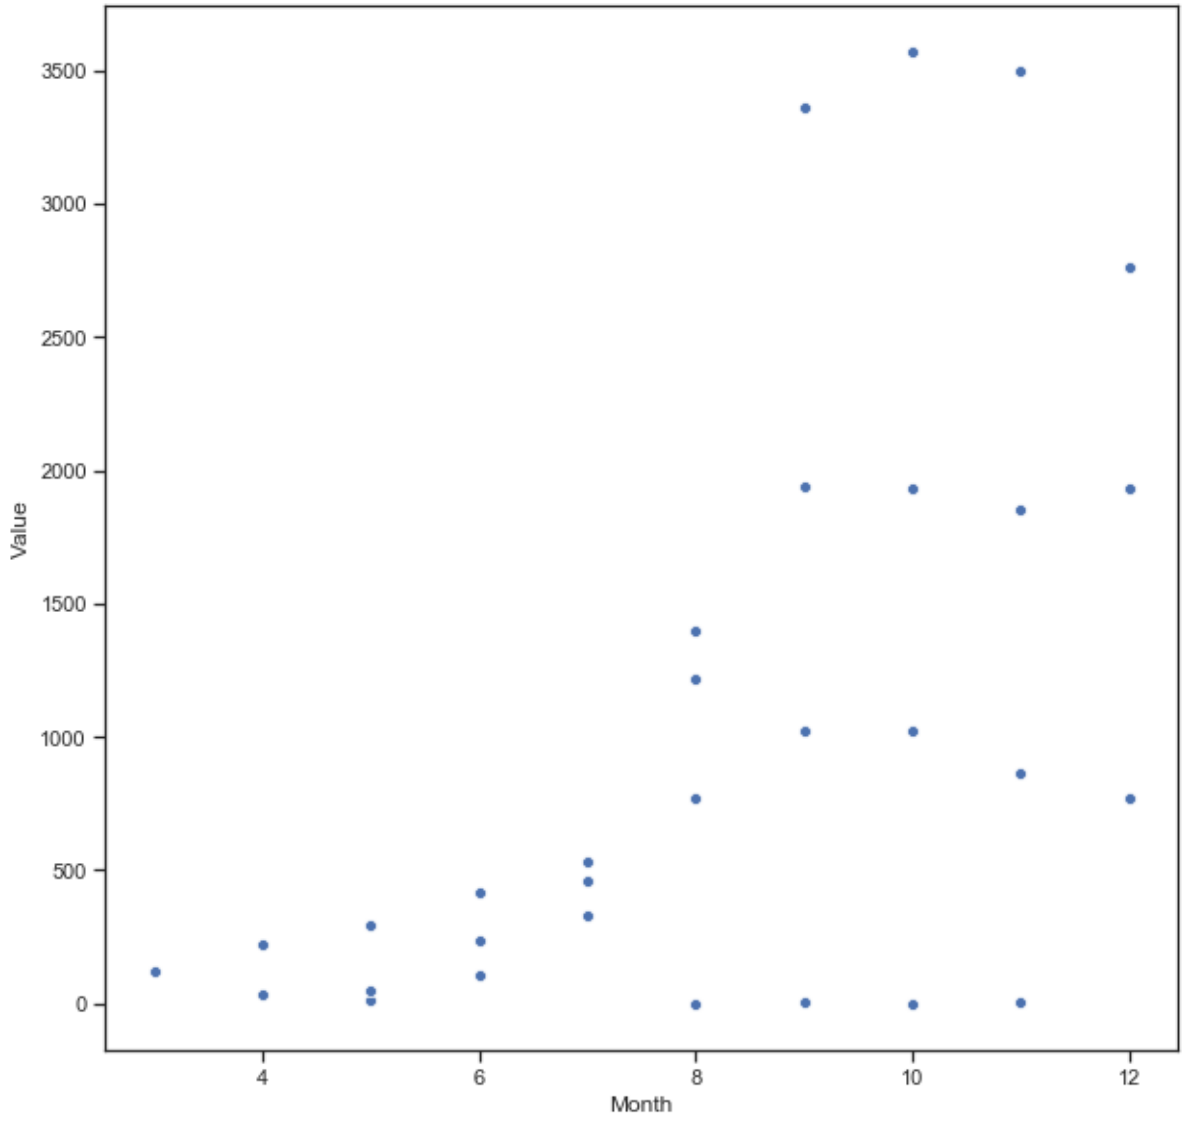

Можно видеть что между полями Humidity и HumidityRatio пристутствует почти линейная зависимость.

Посмотрим насколько на эту зависимость влияет целевой признак.

In [74]:
```
fig, ax = plt.subplots(figsize=(10,10))
sns.scatterplot(ax=ax, x='Month', y='Value', data=data, hue='Year')
```

Out[74]: <matplotlib.axes._subplots.AxesSubplot at 0x130bfecd0>

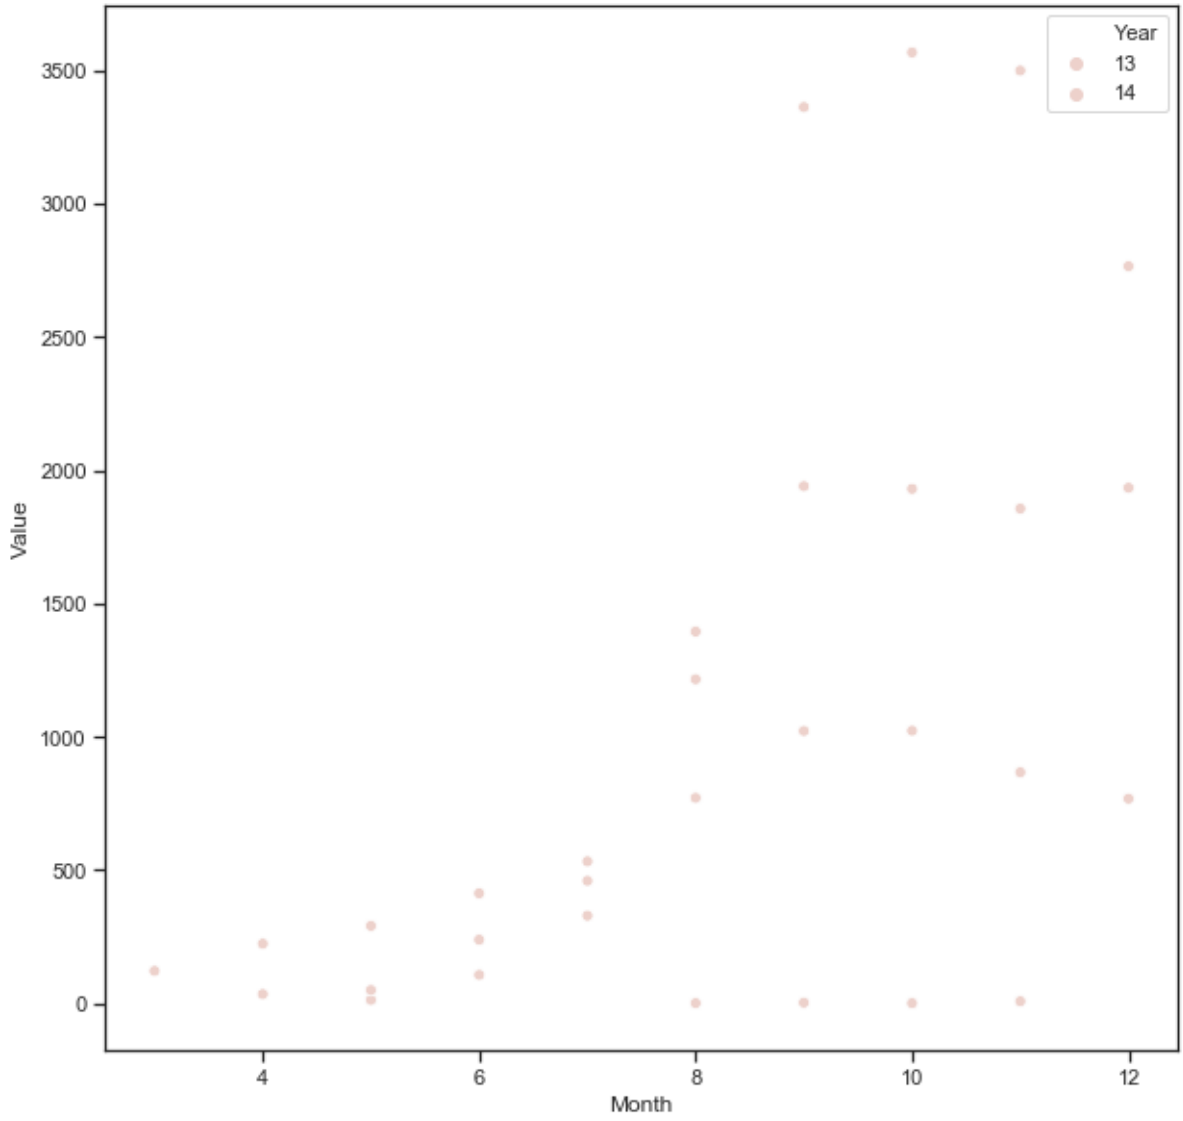

Гистограмма (https://en.wikipedia.org/wiki/Histogram)

Позволяет оценить плотность вероятности распределения данных.

In [75]:
```
fig, ax = plt.subplots(figsize=(10,10))
sns.distplot(data['Month'])
```

Out[75]: <matplotlib.axes._subplots.AxesSubplot at 0x131005990>

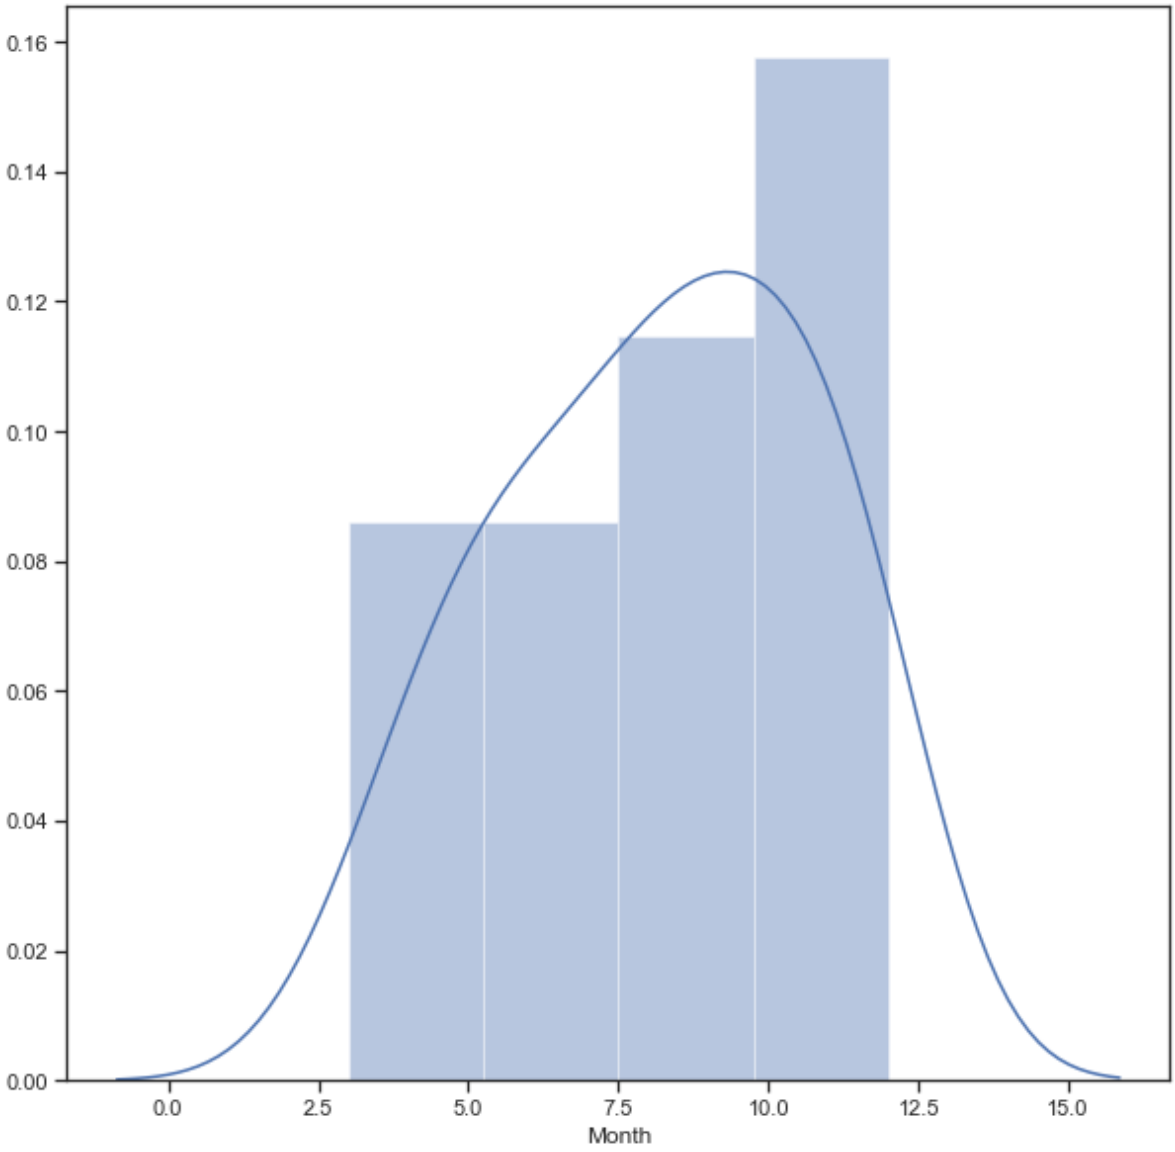

Jointplot

Комбинация гистограмм и диаграмм рассеивания.

In [76]:
```
sns.jointplot(x='Month', y='Value', data=data)
```

Out[76]: <seaborn.axisgrid.JointGrid at 0x130a36190>

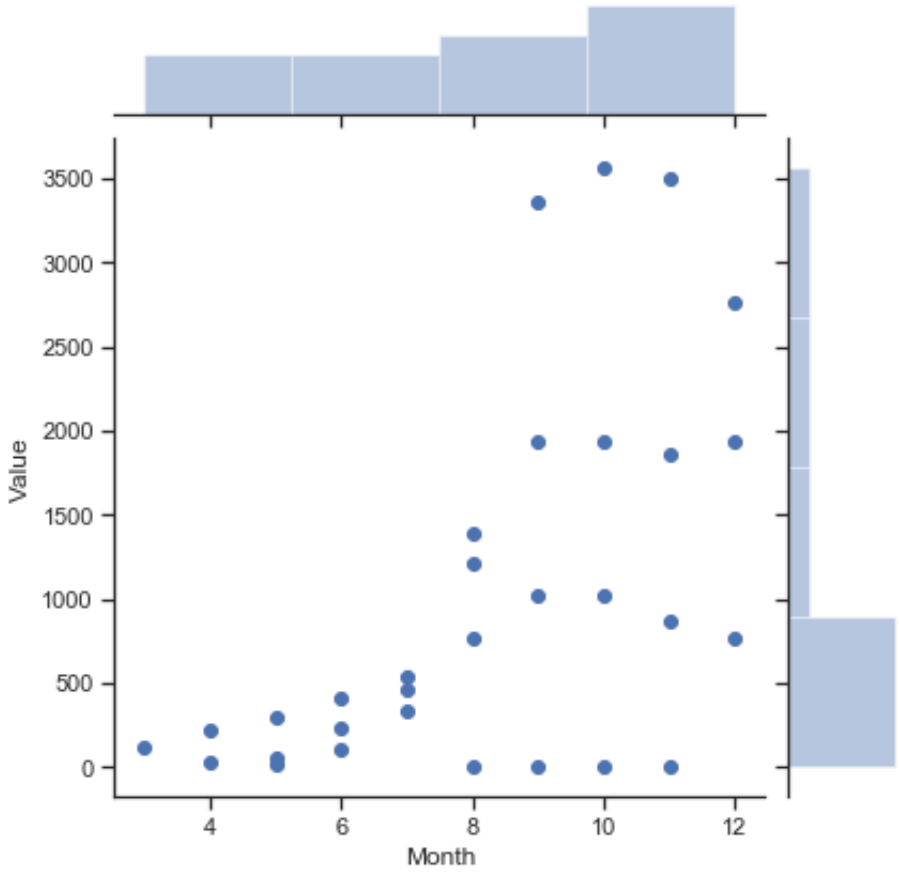

In [77]:
```
sns.jointplot(x='Month', y='Value', data=data, kind="hex")
```

Out[77]: <seaborn.axisgrid.JointGrid at 0x131540210>

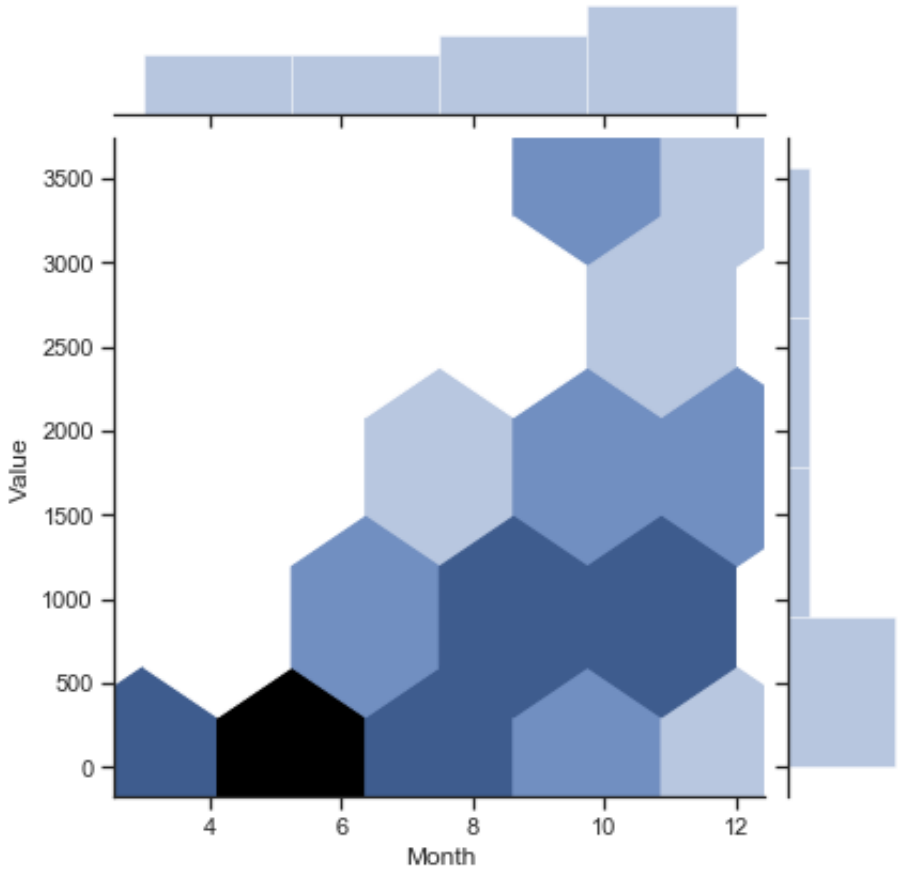

In [ ]:

In [78]:
```
sns.jointplot(x='Month', y='Value', data=data, kind="kde")
```

Out[78]:
```
<seaborn.axisgrid.JointGrid at 0x1317dcf10>
```

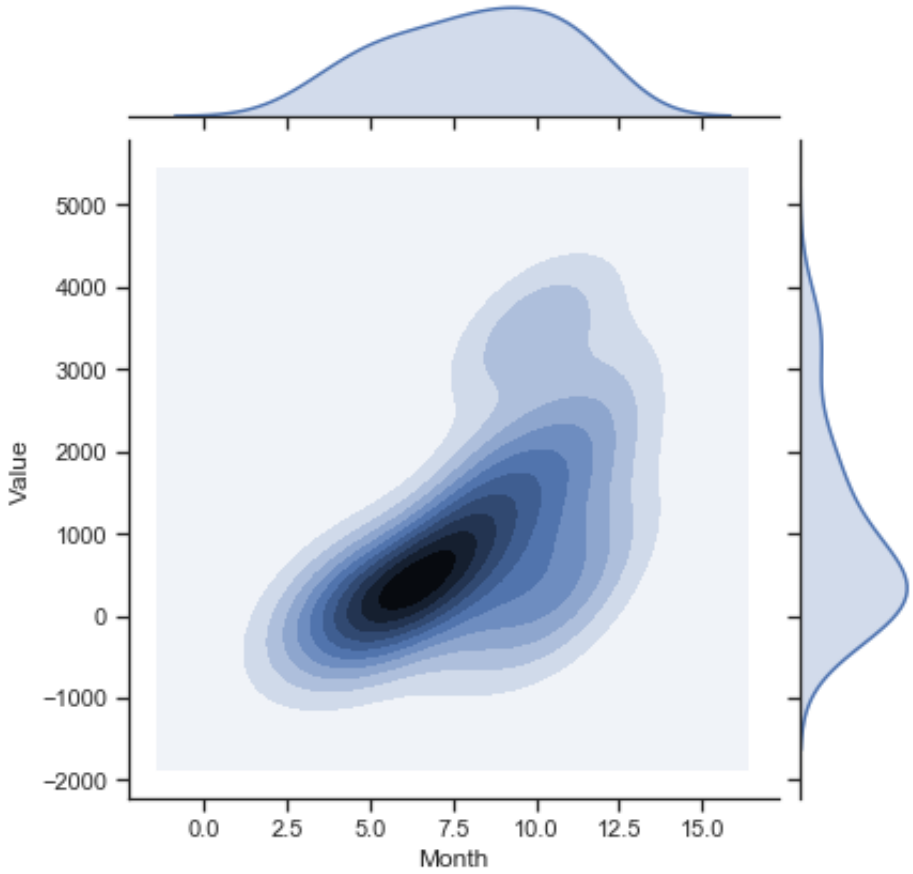

"Парные диаграммы"

Комбинация гистограмм и диаграмм рассеивания для всего набора данных.

Выводится матрица графиков. На пересечении строки и столбца, которые соответстуют двум показателям, строится диаграмма рассеивания. В главной диагонали матрицы строятся гистограммы распределения соответствующих показателей.

In [79]:
```
sns.pairplot(data)
```

Out[79]: <seaborn.axisgrid.PairGrid at 0x131b52d50>

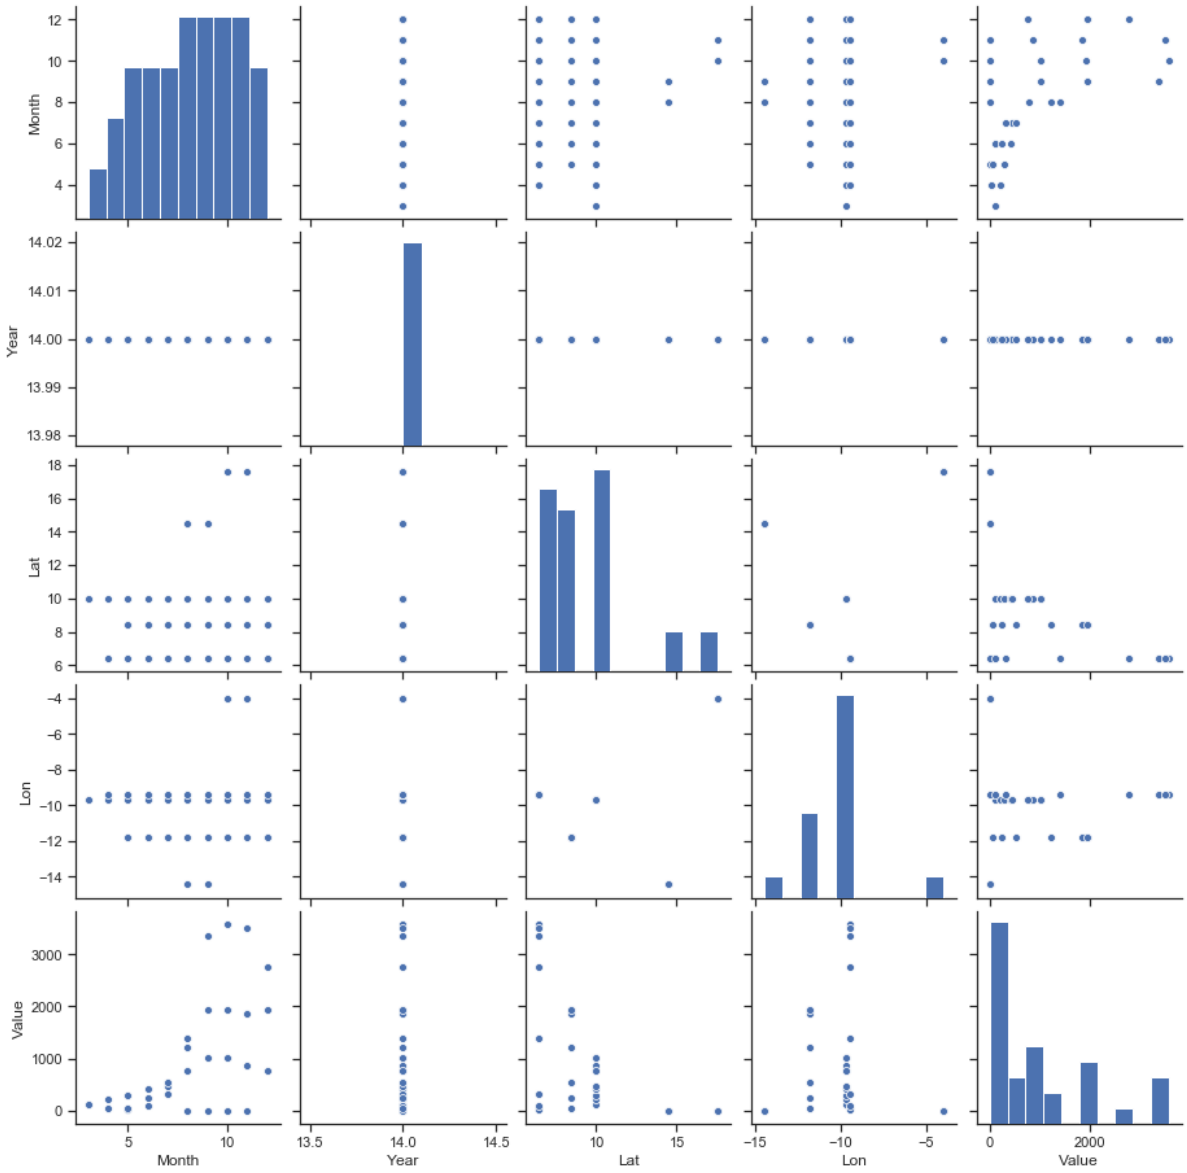

С помощью параметра "hue" возможна группировка по значениям какого-либо признака.

In [80]:
```
sns.pairplot(data, hue="Year")
```

Out[80]: <seaborn.axisgrid.PairGrid at 0x132691ed0>

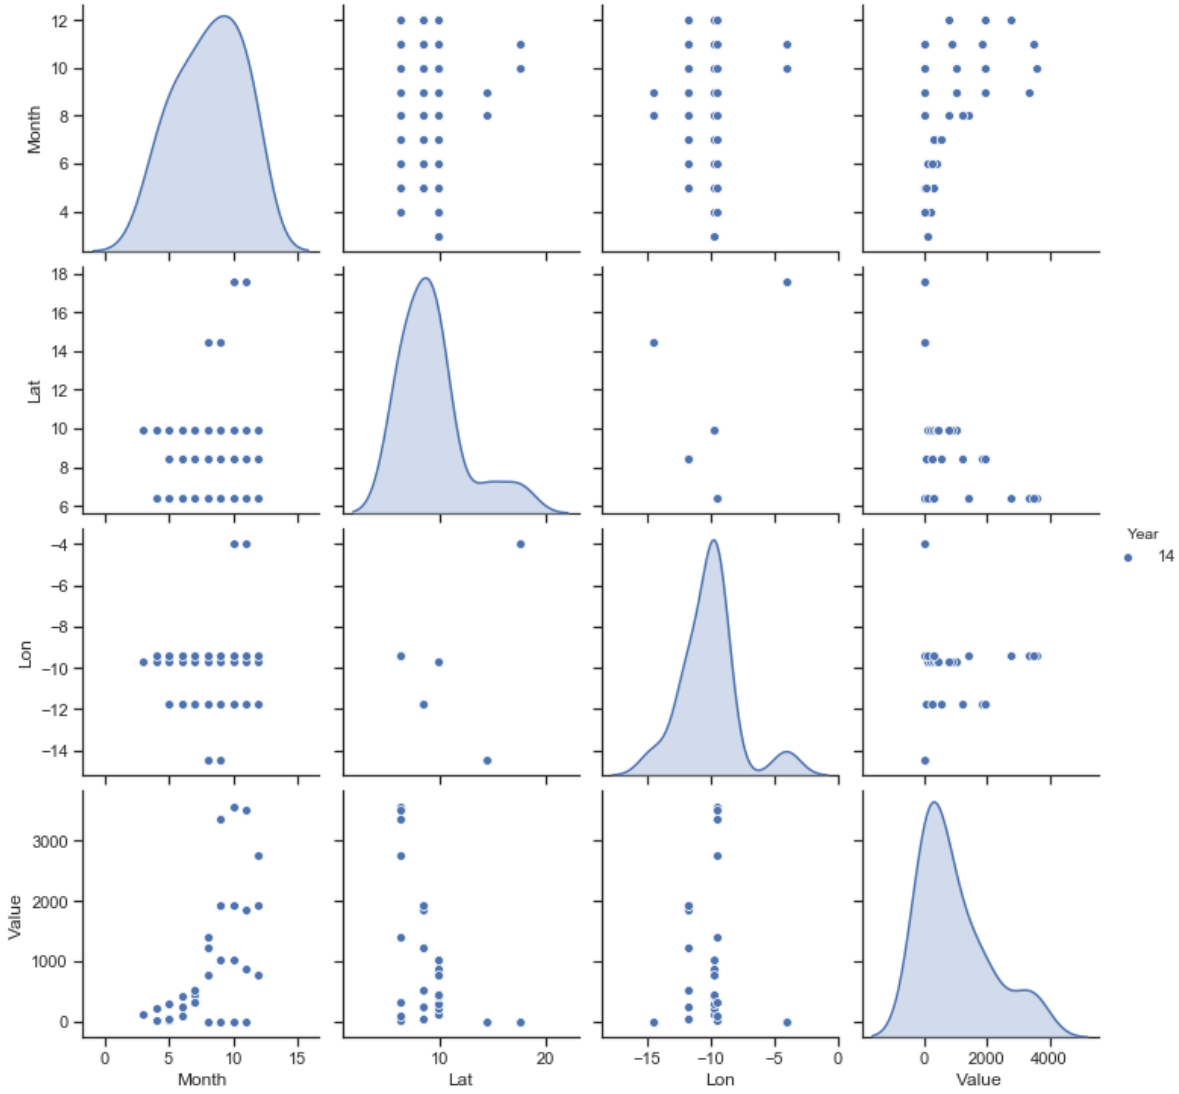

[Ящик с усами (https://en.wikipedia.org/wiki/Box_plot)]

Отображает одномерное распределение вероятности.

In [81]:
```
sns.boxplot(x=data['Month'])
```

Out[81]: <matplotlib.axes._subplots.AxesSubplot at 0x132febc50>

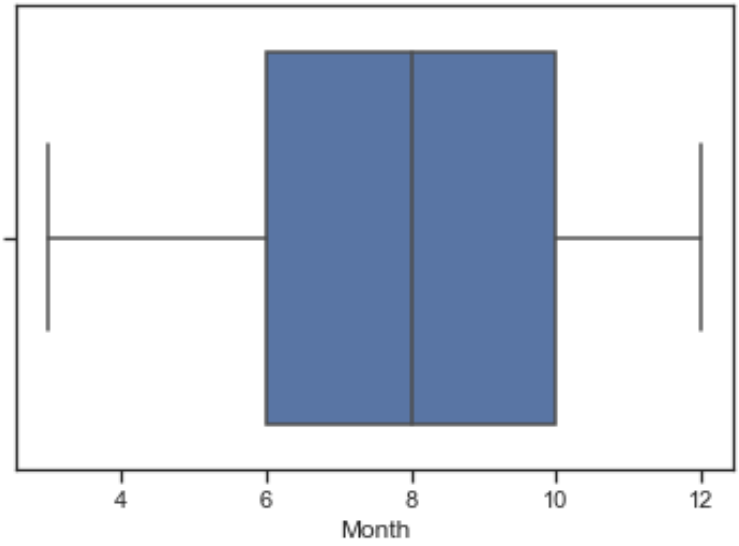

In [82]:
```
# По вертикали
sns.boxplot(y=data['Month'])
```

Out[82]: <matplotlib.axes._subplots.AxesSubplot at 0x1334c5750>

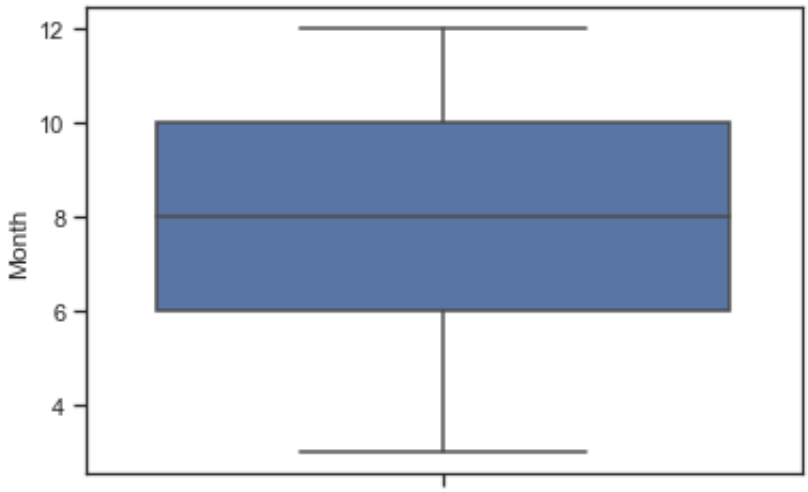

In [83]:
```
# Распределение параметра Humidity сгруппированные по Occupancy.
sns.boxplot(x='Year', y='Month', data=data)
```

Out[83]: <matplotlib.axes._subplots.AxesSubplot at 0x1335f2350>

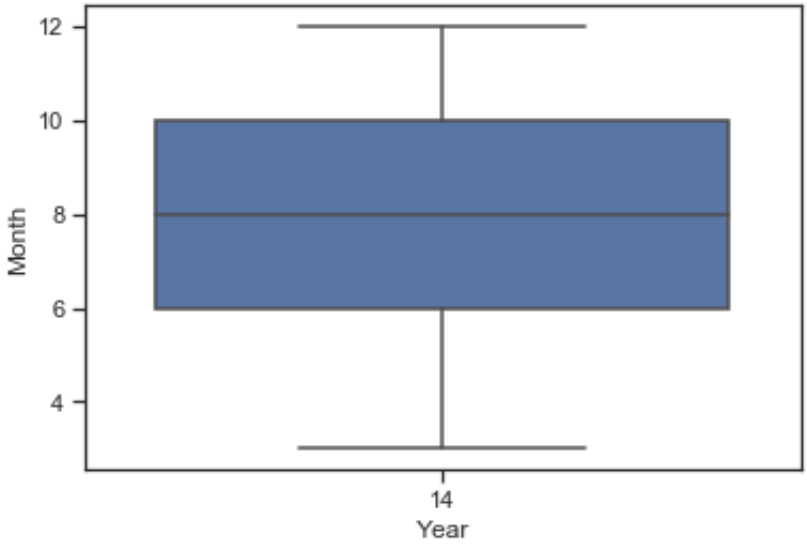

Violin plot (https://en.wikipedia.org/wiki/Violin_plot)

Похоже на предыдущую диаграмму, но по краям отображаются распределения плотности - https://en.wikipedia.org/wiki/Kernel_density_estimation (https://en.wikipedia.org/wiki/Kernel_density_estimation)

In [84]:
```
sns.violinplot(x=data['Month'])
```

Out[84]: <matplotlib.axes._subplots.AxesSubplot at 0x1336bd1d0>

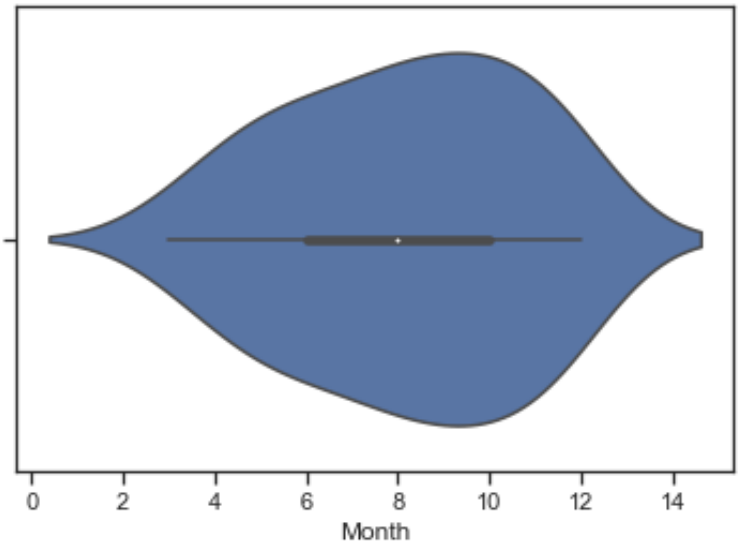

In [85]:
```
fig, ax = plt.subplots(2, 1, figsize=(10,10))
sns.violinplot(ax=ax[0], x=data['Month'])
sns.distplot(data['Month'], ax=ax[1])
```

Out[85]: <matplotlib.axes._subplots.AxesSubplot at 0x13383a850>

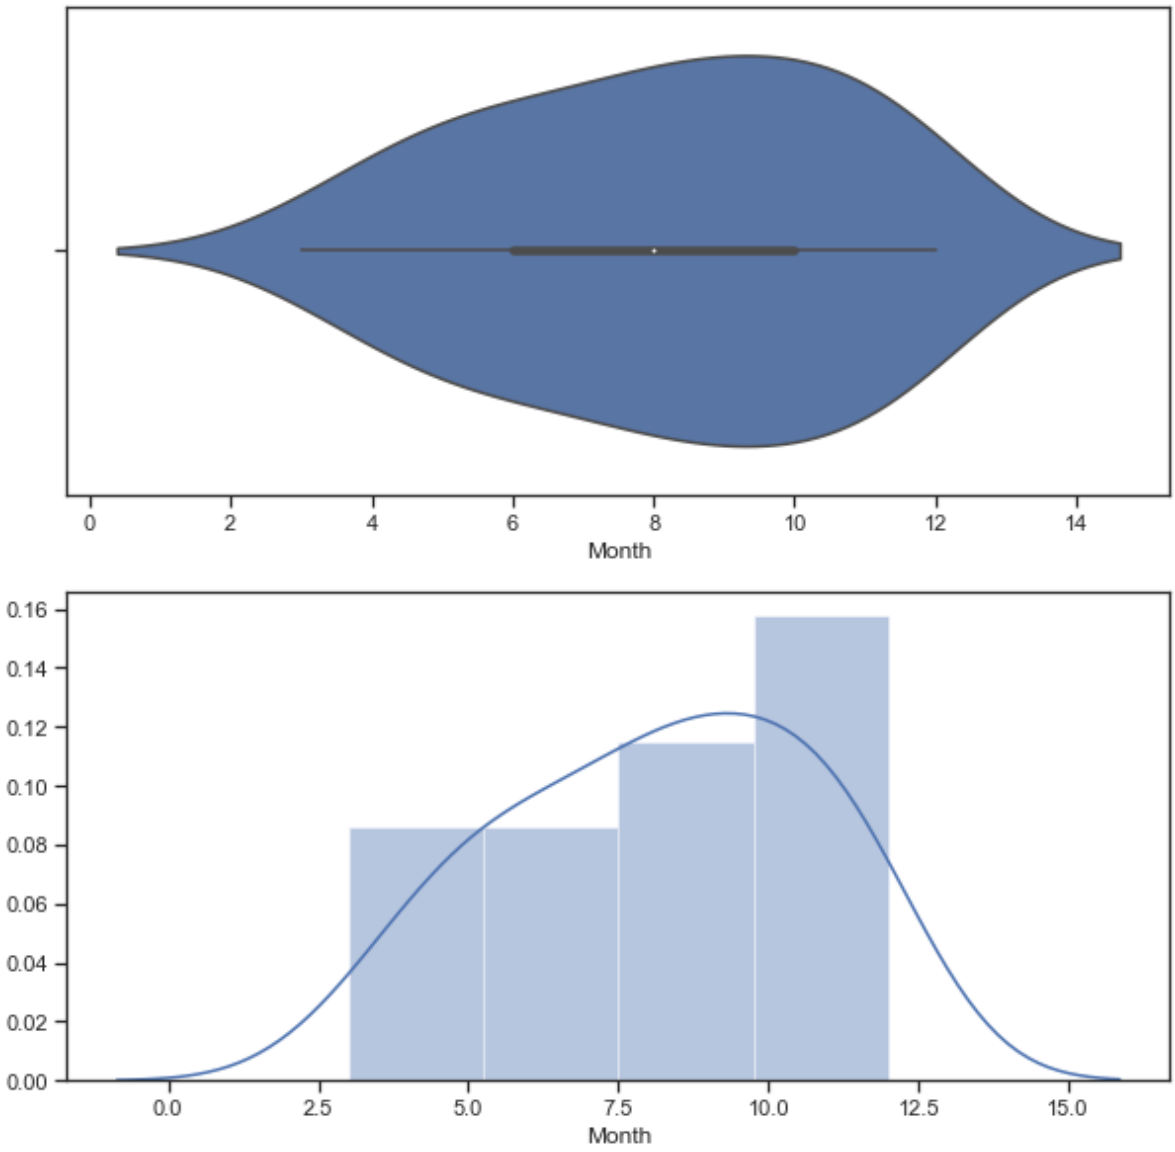

Из приведенных графиков видно, что violinplot действительно показывает распределение плотности.

In [86]:
```
# Распределение параметра Humidity сгруппированные по Occupancy.
sns.violinplot(x='Year', y='Month', data=data)
```

Out[86]: <matplotlib.axes._subplots.AxesSubplot at 0x1338f50d0>

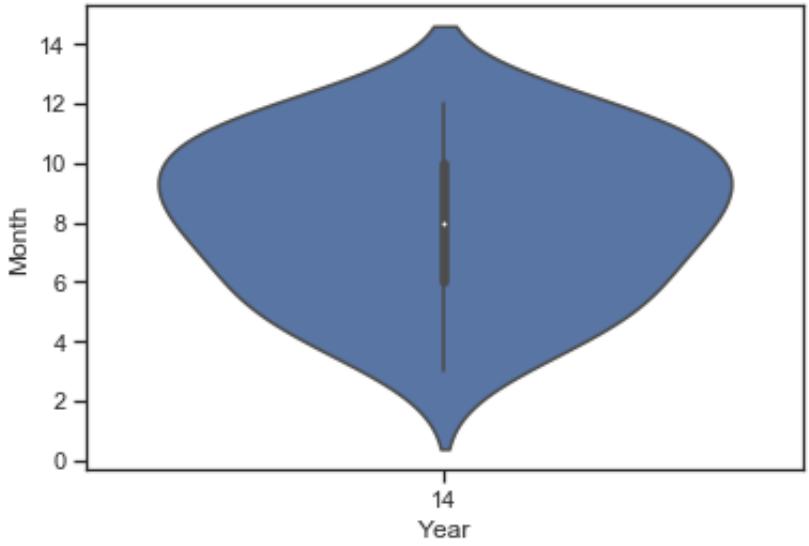

In [87]:
```
sns.catplot(y='Month', x='Year', data=data, kind="violin", split=True)
```

Out[87]: <seaborn.axisgrid.FacetGrid at 0x1338cdd10>

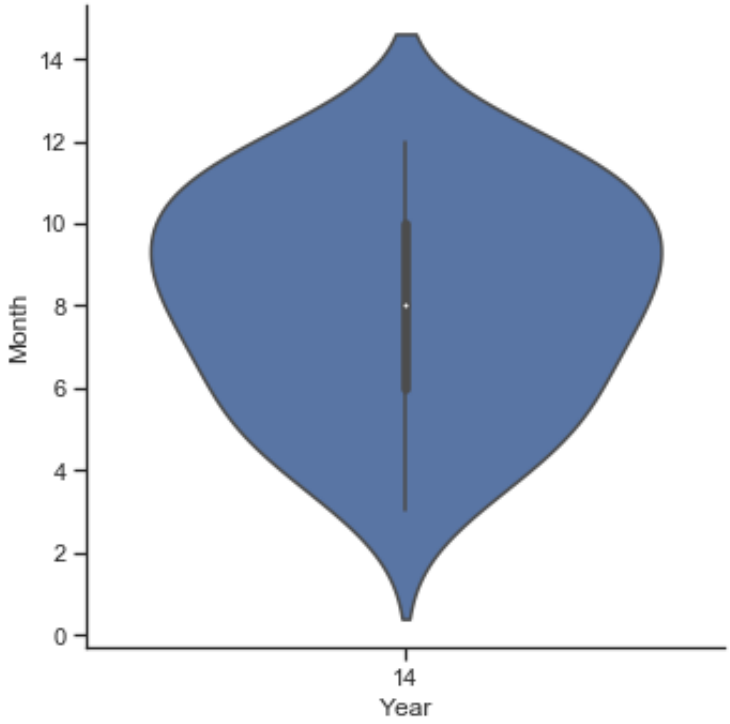

4) Информация о корреляции признаков

Проверка корреляции признаков позволяет решить две задачи:

1. Понять какие признаки (колонки датасета) наиболее сильно коррелируют с целевым признаком (в нашем примере это колонка "Occupancy"). Именно эти признаки будут наиболее информативными для моделей машинного обучения. Признаки, которые слабо коррелируют с целевым признаком, можно попробовать исключить из построения модели, иногда это повышает качество модели. Нужно отметить, что некоторые алгоритмы машинного обучения автоматически определяют ценность того или иного признака для построения модели.
2. Понять какие нецелевые признаки линейно зависимы между собой. Линейно зависимые признаки, как правило, очень плохо влияют на качество моделей. Поэтому если несколько признаков линейно зависимы, то для построения модели из них выбирают какой-то один признак.

In [88]:
```
data.corr()
```

Out[88]:

	Month	Year	Lat	Lon	Value
Month	1.000000	NaN	0.168818	0.103333	0.574907
Year	NaN	NaN	NaN	NaN	NaN
Lat	0.168818	NaN	1.000000	0.265831	-0.482084
Lon	0.103333	NaN	0.265831	1.000000	-0.053895
Value	0.574907	NaN	-0.482084	-0.053895	1.000000

Корреляционная матрица содержит коэффициенты корреляции между всеми парами признаков.

Корреляционная матрица симметрична относительно главной диагонали. На главной диагонали расположены единицы (корреляция признака самого с собой).

На основе корреляционной матрицы можно сделать следующие выводы:

- Целевой признак наиболее сильно коррелирует с освещенностью (0.9) и концентрацией углекислого газа (0.71). Эти признаки обязательно следует оставить в модели.
- Целевой признак отчасти коррелирует с температурой (0.54). Этот признак стоит также оставить в модели.
- Целевой признак слабо коррелирует с влажностью (0.13) и HumidityRatio (0.3). Скорее всего эти признаки стоит исключить из модели, возможно они только ухудшат качество модели.
- Влажность и HumidityRatio очень сильно коррелируют между собой (0.96). Это неудивительно, ведь HumidityRatio величина производная от влажности. Поэтому из этих признаков в модели можно оставлять только один.
- Также можно сделать вывод, что выбирая из признаков влажность и HumidityRatio лучше выбрать HumidityRatio, потому что он сильнее коррелирован с целевым признаком. Если линейно зависимые признаки сильно коррелированы с целевым, то оставляют именно тот признак, который коррелирован с целевым сильнее. Но для этой пары признаков этот вывод нельзя считать надежным, потому что и 0.13 и 0.3 являются довольно малыми величинами.

Описание метода corr - https://pandas.pydata.org/pandas-docs/stable/reference/api/pandas.DataFrame.corr.html (https://pandas.pydata.org/pandas-docs/stable/reference/api/pandas.DataFrame.corr.html)

По умолчанию при построении матрицы используется коэффициент корреляции Пирсона (https://ru.wikipedia.org/wiki/%D0%9A%D0%BE%D1%80%D1%80%D0%B5%D0%BB%D1%8F%D1%
Возможно также построить корреляционную матрицу на основе коэффициентов корреляции Кендалла и Спирмена. На практике три метода редко дают значимые различия.

In [89]:
```
data.corr(method='pearson')
```

Out[89]:

	Month	Year	Lat	Lon	Value
Month	1.000000	NaN	0.168818	0.103333	0.574907
Year	NaN	NaN	NaN	NaN	NaN
Lat	0.168818	NaN	1.000000	0.265831	-0.482084
Lon	0.103333	NaN	0.265831	1.000000	-0.053895
Value	0.574907	NaN	-0.482084	-0.053895	1.000000

In [90]:
```
data.corr(method='kendall')
```

Out[90]:

	Month	Year	Lat	Lon	Value
Month	1.000000	NaN	0.059089	0.033398	0.428600
Year	NaN	1.0	NaN	NaN	NaN
Lat	0.059089	NaN	1.000000	-0.220339	-0.402186
Lon	0.033398	NaN	-0.220339	1.000000	-0.027141
Value	0.428600	NaN	-0.402186	-0.027141	1.000000

In [91]:
```
data.corr(method='spearman')
```

Out[91]:

	Month	Year	Lat	Lon	Value
Month	1.000000	NaN	0.070097	0.049226	0.533166
Year	NaN	NaN	NaN	NaN	NaN
Lat	0.070097	NaN	1.000000	-0.294400	-0.484025
Lon	0.049226	NaN	-0.294400	1.000000	-0.002935
Value	0.533166	NaN	-0.484025	-0.002935	1.000000

В случае большого количества признаков анализ числовой корреляционной матрицы становится неудобен.

Для визуализации корреляционной матрицы будем использовать "тепловую карту" heatmap которая показывает степень корреляции различными цветами.

Используем метод heatmap библиотеки seaborn - https://seaborn.pydata.org/generated/seaborn.heatmap.html (https://seaborn.pydata.org/generated/seaborn.heatmap.html)

In [92]:
```
sns.heatmap(data.corr())
```

Out[92]: <matplotlib.axes._subplots.AxesSubplot at 0x133c26c50>

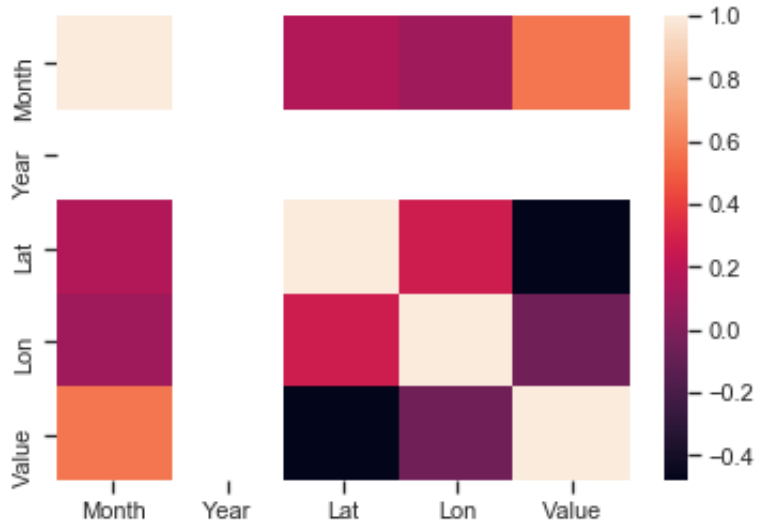

In [93]:
```
# Вывод значений в ячейках
sns.heatmap(data.corr(), annot=True, fmt='.3f')
```

Out[93]: <matplotlib.axes._subplots.AxesSubplot at 0x133d651d0>

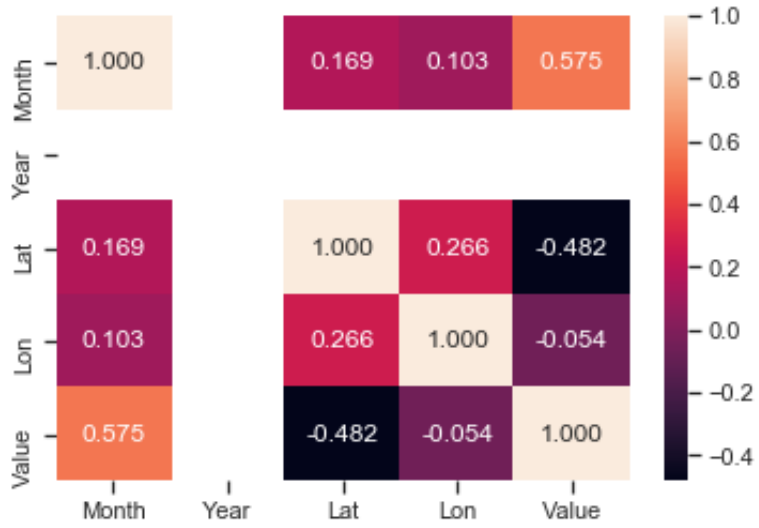

In [94]:
```
# Изменение цветовой гаммы
sns.heatmap(data.corr(), cmap='YlGnBu', annot=True, fmt='.3f')
```

Out[94]: <matplotlib.axes._subplots.AxesSubplot at 0x133ebae10>

In [95]:
```
# Треугольный вариант матрицы
mask = np.zeros_like(data.corr(), dtype=np.bool)
# чтобы оставить нижнюю часть матрицы
# mask[np.triu_indices_from(mask)] = True
# чтобы оставить верхнюю часть матрицы
mask[np.tril_indices_from(mask)] = True
sns.heatmap(data.corr(), mask=mask, annot=True, fmt='.3f')
```

Out[95]: <matplotlib.axes._subplots.AxesSubplot at 0x133ff7450>

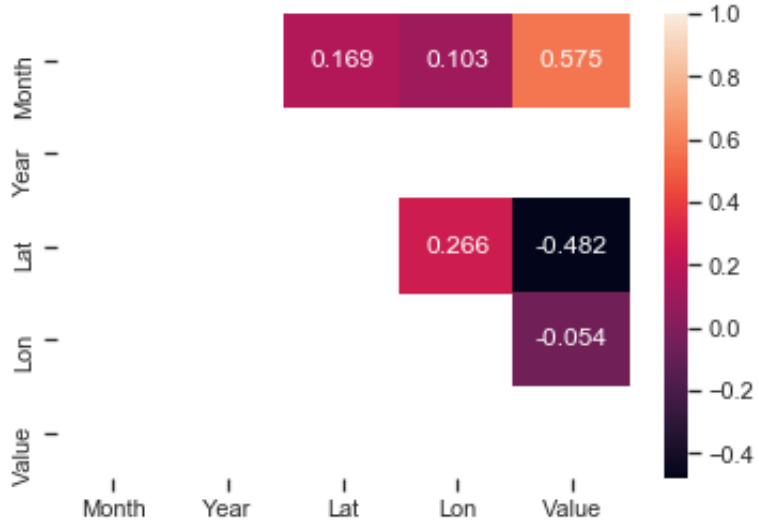

In [96]:
```
fig, ax = plt.subplots(1, 3, sharex='col', sharey='row', figsize=(15,5))
sns.heatmap(data.corr(method='pearson'), ax=ax[0], annot=True, fmt='.2f')
sns.heatmap(data.corr(method='kendall'), ax=ax[1], annot=True, fmt='.2f')
sns.heatmap(data.corr(method='spearman'), ax=ax[2], annot=True, fmt='.2f')
fig.suptitle('Корреляционные матрицы, построенные различными методами')
ax[0].title.set_text('Pearson')
ax[1].title.set_text('Kendall')
ax[2].title.set_text('Spearman')
```

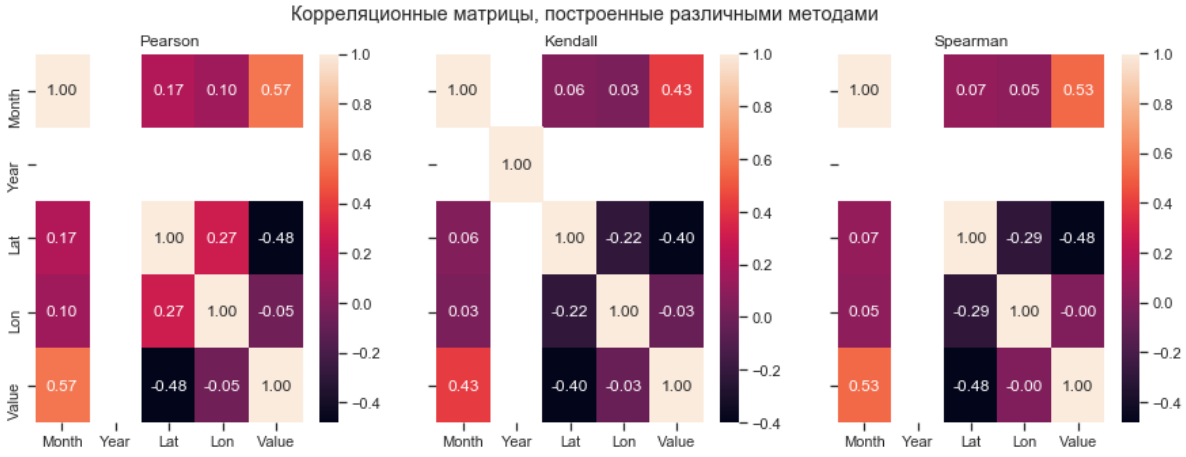

Необходимо отметить, что тепловая карта не очень хорошо подходит для определения корреляции нецелевых признаков между собой.

В примере тепловая карта помогает определить значимую корреляцию между признаками Humidity и HumidityRatio, следовательно только один из этих признаков можно включать в модель.

Но в реальной модели могут быть сотни признаков и коррелирующие признаки могут образовывать группы, состоящие более чем из двух признаков. Увидеть такие группы с помощью тепловой карты сложно.

Для решения задачи предлагается новый вариант визуализации - "Солнечная корреляционная карта" Solar correlation map (https://github.com/Zapf-Consulting/solar-correlation-map).

К сожалению, данная библиотека пока работает только через файловый интерфейс и не предназначена для встраивания в ноутбук.

Примеры статей с описанием работы библиотеки:

- https://www.oreilly.com/learning/a-new-visualization-to-beautifully-explore-correlations (https://www.oreilly.com/learning/a-new-visualization-to-beautifully-explore-correlations)
- https://www.mtab.com/the-puzzle-of-visualizing-correlations/ (https://www.mtab.com/the-puzzle-of-visualizing-correlations/)

Дополнительные ссылки на обучающие ноутбуки

The Best Tutorial for Beginners (Kaggle) (https://www.kaggle.com/getting-started/71679)

In [ ]:

In [ ]:

In [ ]:

In [ ]: