### Цель лабораторной работы:

Изучение сложных способов подготовки выборки и подбора гиперпараметров на примере метода ближайших соседей.

#### Задание:

- 1. Выберите набор данных (датасет) для решения задачи классификации или регресии.
- 2. В случае необходимости проведите удаление или заполнение пропусков и кодирование категориальных признаков.
- 3. С использованием метода train\_test\_split разделите выборку на обучающую и тестовую.
- 4. Обучите модель ближайших соседей для произвольно заданного гиперпараметра К. Оцените качество модели с помощью трех подходящих для задачи метрик.
- 5. Постройте модель и оцените качество модели с использованием кросс-валидации. Проведите эксперименты с тремя различными стратегиями кросс-валидации.
- 6. Произведите подбор гиперпараметра К с использованием GridSearchCV и кросс-валидации.
- 7. Повторите пункт 4 для найденного оптимального значения гиперпараметра К. Сравните качество полученной модели с качеством модели, полученной в пункте 4.
- 8. Постройте кривые обучения и валидации.

### 1. Выбор набора данных (датасета) для решения задачи классификации или регресии.

```
In [1]: import numpy as np
   import pandas as pd
   import matplotlib.pyplot as plt
   from sklearn.metrics import mean_absolute_error, median_absolute_er
   ror, r2_score
   from sklearn.model_selection import GridSearchCV
   from sklearn.model_selection import KFold, RepeatedKFold, LeavePOut
   , ShuffleSplit, StratifiedKFold
   from sklearn.model_selection import cross_val_score, train_test_spl
   it
   from sklearn.model_selection import learning_curve, validation_curv
   e
   from sklearn.neighbors import KNeighborsRegressor
   # Enable inline plots
%matplotlib inline
```

```
data = pd.read csv('data/covid 19 clean complete.csv', sep=',')
In [2]:
         data.head()
Out[2]:
             Province/State Country/Region
                                            Lat
                                                          Date Confirmed Deaths
                                                                                 Recover
                                                   Long
                                         33.0000
                                                                       0
          0
                     NaN
                              Afghanistan
                                                 65.0000 1/22/20
                                                                              0
          1
                     NaN
                                 Albania
                                         41.1533
                                                20.1683 1/22/20
                                                                       0
                                                                              0
                     NaN
          2
                                 Algeria
                                         28.0339
                                                 1.6596 1/22/20
                                                                       0
                                                                              0
                     NaN
          3
                                 Andorra
                                         42.5063
                                                 1.5218 1/22/20
                                                                       0
                                                                              0
                     NaN
                                                                       0
                                                                              0
                                 Angola -11.2027 17.8739 1/22/20
In [3]:
         data.shape
Out[3]: (17136, 8)
In [4]:
         data.isnull().sum()
Out[4]: Province/State
                              11832
         Country/Region
                                   0
         Lat
                                   0
                                   0
         Long
         Date
                                   0
         Confirmed
                                   0
         Deaths
                                   0
                                   0
         Recovered
         dtype: int64
In [5]:
         data.dtypes
Out[5]: Province/State
                               object
                               object
         Country/Region
                              float64
         Lat
                              float64
         Long
                               object
         Date
         Confirmed
                                 int64
         Deaths
                                 int.64
         Recovered
                                 int64
```

### 2. Заполнение пропусков и кодирование категориальных признаков

#### Заполнение пропусков

dtype: object

```
In [6]: data = data.fillna('')
         data.isnull().sum()
Out[6]: Province/State
                            0
        Country/Region
                            0
        Lat
                            0
        Long
                            0
        Date
                            0
        Confirmed
                            0
        Deaths
        Recovered
                            0
         dtype: int64
In [7]: data.dtypes
Out[7]: Province/State
                             object
        Country/Region
                             object
        Lat
                            float64
        Long
                            float64
                             object
        Date
        Confirmed
                              int64
        Deaths
                              int64
        Recovered
                              int64
        dtype: object
```

#### Кодирование категориальных признаков числовыми

```
In [8]:
        from sklearn.preprocessing import LabelEncoder
        le = LabelEncoder()
        data['Province/State'] = le.fit transform(data['Province/State'])
        data['Date'] = le.fit transform(data['Date'])
        data['Country/Region'] = le.fit transform(data['Country/Region'])
        data.dtypes
Out[8]: Province/State
                             int64
        Country/Region
                             int64
        Lat
                           float64
        Long
                           float64
        Date
                             int64
        Confirmed
                             int64
        Deaths
                             int64
        Recovered
                             int64
        dtype: object
```

```
In [9]: data.head()
```

Out[9]:

	Province/State	Country/Region	Lat	Long	Date	Confirmed	Deaths	Recovered
0	0	0	33.0000	65.0000	0	0	0	0
1	0	1	41.1533	20.1683	0	0	0	0
2	0	2	28.0339	1.6596	0	0	0	0
3	0	3	42.5063	1.5218	0	0	0	0
4	0	4	-11.2027	17.8739	0	0	0	0

### 3. Разделение выборки на обучающую и тестовую с использованием метода train\_test\_split p.

#### Х - признаки

#### У - целевые значения

```
In [15]: y_test.shape
Out[15]: (4456,)
```

# 4. Обучение модели ближайших соседей для произвольно заданного гиперпараметра К. Оценка качества модели с помощью трех подходящих для задачи метрик.

#### 4.1. Mean absolute error

#### 4.2. Median absolute error

```
In [18]: med_ae4 = median_absolute_error(y_test, kn_regressor.predict(X_test
))
    med_ae4
Out[18]: 0.0
```

#### 4.3. r2 score

## 5. Построение модели и оценка качества модели с использованием кросс-валидации. Проведение эксперимента с тремя различными стратегиями кросс-валидации.

```
In [20]: kn_regressor = KNeighborsRegressor(n_neighbors=5)
```

#### K-Fold

#### Repeated K-Fold

#### **Shuffle Split**

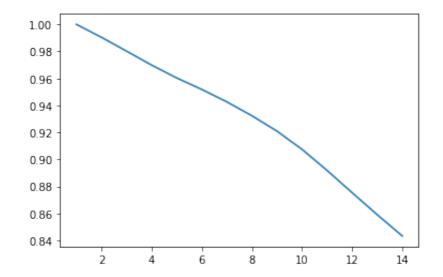
```
In [25]: cv strategy = ShuffleSplit(n splits=5, test size=0.25)
        cv score = cross val score(kn regressor, X, y, cv=cv strategy, scor
        ing="r2")
        cv score
Out[25]: array([0.96649471, 0.20545483, 0.88645067, 0.86829366, 0.98402359]
In [26]: | cv strategy = ShuffleSplit(n splits=5, test size=0.4)
        for train, test in cv strategy.split(X):
            print("%s %s" % (train, test))
        [ 7766 12847 14526 ... 1206 6194 13842] [ 5721 11083 8444 ...
        715
            4629 7421]
        [ 2008 9125 8357 ... 11849 16759 286] [ 5137 8468 14259 ...
        755 14920 2263]
        [ 8018 9796
                    6178 ... 15454 5151 9583] [ 8714 11028 6794 ...
        7794 3967 129831
        [10589 13612 9827 ... 13908 9085 3902] [8310 8899 248 ... 4086
        8628 8411]
           5008 2589 126881
In [27]: cv score.mean()
Out[27]: 0.7821434917444716
```

### 6. Подбор гиперпараметра K с использованием GridSearchCV и кроссвалидации.

```
In [30]: grid search.fit(X, y)
Out[30]: GridSearchCV(cv=RepeatedKFold(n repeats=2, n splits=5, random stat
         e=None),
                      error score=nan,
                      estimator=KNeighborsRegressor(algorithm='auto', leaf
         size=30,
                                                    metric='minkowski',
                                                    metric_params=None, n_j
         obs=None,
                                                    n neighbors=5, p=2,
                                                    weights='uniform'),
                      iid='deprecated', n jobs=-1,
                      param_grid=[{'n_neighbors': array([ 1,  2,  3,  4,
                                                                           5
            6, 7, 8, 9, 10, 11, 12, 13, 14])}],
                      pre dispatch='2*n jobs', refit=True, return train sco
         re=True,
                      scoring='r2', verbose=0)
In [31]: grid search.best params
Out[31]: {'n neighbors': 1}
In [32]: grid search.best score
Out[32]: 0.9633345750733049
In [33]: grid search.best estimator
Out[33]: KNeighborsRegressor(algorithm='auto', leaf size=30, metric='minkow
         ski',
                             metric params=None, n jobs=None, n neighbors=1
         p=2
                             weights='uniform')
```

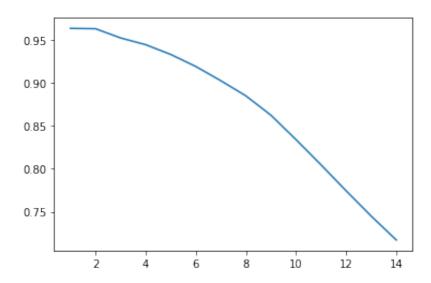
```
In [34]: plt.plot(n_range, grid_search.cv_results_["mean_train_score"])
```

Out[34]: [<matplotlib.lines.Line2D at 0x7fd142a6cf90>]



```
In [35]: plt.plot(n_range, grid_search.cv_results_["mean_test_score"])
```

Out[35]: [<matplotlib.lines.Line2D at 0x7fd1422db490>]



# 7. Обучение модели ближайших соседей для найденного оптимального значения гиперпараметра К. Оценка качества модели с помощью трех метрик. Сравнение качества полученной модели с качеством модели, полученной в пункте 4.

```
In [36]: kn_regressor_best = KNeighborsRegressor(**grid_search.best_params_)
```

#### Сравнение качества модели с п.4

#### 7.1. Mean absolute error

```
In [38]: mae7 = mean_absolute_error(y_test, kn_regressor_best.predict(X_test
))
mae7
Out[38]: 37.915170556552965
```

Из п.4

```
In [39]: mae4
Out[39]: 40.97425621954346
```

#### 7.2. Median absolute error

```
In [40]: med_ae7 = median_absolute_error(y_test, kn_regressor_best.predict(X
    _test))
    med_ae7
Out[40]: 0.0
```

Из п.4

```
In [41]: med_ae4
Out[41]: 0.0
```

#### 7.3. r2 score

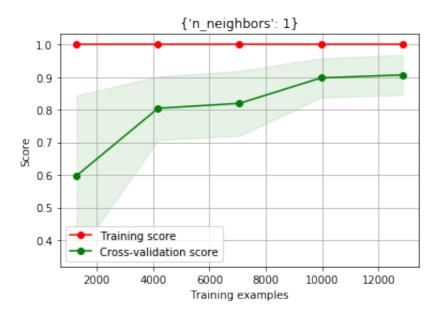
Из п.4

```
In [43]: r2_4
Out[43]: 0.959735318140834
```

#### 8. Построение кривых обучения и валидации.

```
In [44]: def plot learning curve(estimator, title, X, y, ylim=None, cv=None)
             train sizes=np.linspace(.1, 1.0, 5)
             plt.figure()
             plt.title(title)
             if ylim is not None:
                 plt.ylim(*ylim)
             plt.xlabel("Training examples")
             plt.ylabel("Score")
             train sizes, train scores, test scores = learning curve(
                 estimator, X, y, cv=cv, n jobs=-1, train sizes=train sizes)
             train scores mean = np.mean(train scores, axis=1)
             train scores std = np.std(train scores, axis=1)
             test scores mean = np.mean(test scores, axis=1)
             test scores std = np.std(test scores, axis=1)
             plt.grid()
             plt.fill between(train sizes,
                               train scores mean - train scores std,
                               train scores mean + train scores std,
                               alpha=0.1, color="r")
             plt.fill between(train sizes,
                               test scores_mean - test_scores_std,
                               test scores_mean + test_scores_std,
                               alpha=0.1, color="g")
             plt.plot(train sizes, train scores mean,
                       'o-', color="r", label="Training score")
             plt.plot(train sizes, test scores mean,
                       'o-', color="g", label="Cross-validation score")
             plt.legend(loc="best")
             return plt
```

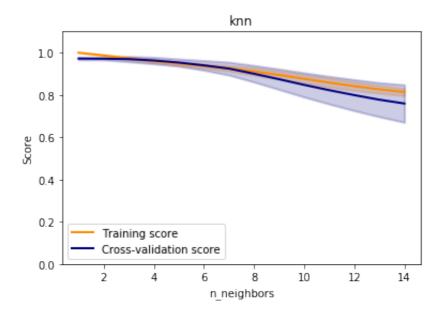
#### Кривая обучения



03.06.2020, 15:16

```
In [46]: def plot validation curve(estimator, title, X, y, param name, param
         _range, cv, scoring="accuracy"):
             train scores, test scores = validation curve(estimator,
                                                           param name=param n
         ame,
                                                           param range=param
         range,
                                                           cv=cv,
                                                           scoring=scoring,
                                                           n jobs=-1)
             train scores mean = np.mean(train scores, axis=1)
             train scores std = np.std(train scores, axis=1)
             test scores mean = np.mean(test scores, axis=1)
             test scores std = np.std(test scores, axis=1)
             plt.title(title)
             plt.xlabel(param name)
             plt.ylabel("Score")
             plt.ylim(0.0, 1.1)
             lw = 2
             plt.plot(param range, train scores mean, label="Training score"
                      color="darkorange", lw=lw)
             plt.fill between(param range,
                               train_scores_mean - train_scores_std,
                               train scores mean + train scores std, alpha=0.
         2,
                               color="darkorange", lw=lw)
             plt.plot(param_range, test_scores_mean,
                       label="Cross-validation score",
                      color="navy", lw=lw)
             plt.fill between(param range, test_scores_mean - test_scores_st
         d,
                               test scores mean + test scores std, alpha=0.2,
                               color="navy", lw=lw)
             plt.legend(loc="best")
             return plt
```

#### Кривая валидации



#### Вывод:

В данной лабораторной работе были подготовлены данные, подобраны гиперпараметры на примере метода ближайших соседей.